

Apprentissage profond et fédéré pour la classification de la densité mammaire

Point d'avancement – résultats par approche

ALLA Abdelouahad

UMONS – Faculté des Sciences
Maître de mémoire : Xavier Lessage (CETIC)
Directeur : Saïd Mahmoudi (UMONS)

7 août 2026

Plan

- 1 Approche 1 – Vision Transformer univarié
- 2 Approche 2 – Fine-tuning direct (ViT / ResNet50)
- 3 Approche 3 – ResNet50 + Histogramme (MLO)
- 4 Approche 4 – ResNet150 + Histogramme (CC)
- 5 Approche 5 – Branche GLCM
- 6 Approche 6 – Architecture à double branche
- 7 Approche 7 – Cascade hiérarchique
- 8 Approche 8 – Ensemble (fusion tardive)
- 9 Apprentissage fédéré (FedAvg)
- 10 Interprétabilité – Approche 3

Approche 1 – Vision Transformer (Twins)

- Backbone Twins Transformer, extraction de features (768D) + MLP 4 classes
- Arbitrage binaire ciblé en cas d'ambiguïté top-2 (paires de classes proches)

Résultats (1808 images de test)

- Classification directe à 4 classes : **76.66 % accuracy globale** – mais rappel nul (0 %) sur la classe A
- Avec arbitrage binaire ciblé : 60.57 % accuracy globale, meilleur rappel sur B (86.63 %)


Approche 2 – ViT (fine-tuning direct)

Test Acc 70.00 % (4000 images) – seule architecture univariée à obtenir un rappel significatif sur la classe A (0.65)

ViT (Approche 2) -- Résultat du test

Test Acc 70.00 % (4000 images, split test complet VinDr-Mammo)

Matrice de confusion (test)



Métriques par classe

	Precision	Recall	F1-score	Support
Densité A	0.32	0.65	0.43	20
Densité B	0.32	0.90	0.48	380
Densité C	0.93	0.67	0.78	3060
Densité D	0.56	0.73	0.64	540
Accuracy			0.70	4000
Macro avg	0.53	0.74	0.58	4000
Weighted	0.82	0.70	0.73	4000


Approche 2 – ResNet50 (fine-tuning direct)

Test Acc 74.00 % (4000 images) – **meilleur rappel classe A** de tout le mémoire (0.95, 19/20)

ResNet50 (fine-tuning) -- Résultat du test final

Test Acc 74.00 % (4000 images) · Train Acc 76.39 % (meilleure époque)

Matrice de confusion (test)




Métriques par classe

	Precision	Recall	F1-score	Support
Densité A	0.30	0.95	0.46	20
Densité B	0.48	0.84	0.61	380
Densité C	0.97	0.70	0.81	3060
Densité D	0.46	0.90	0.61	540
Accuracy			0.74	4000
Macro avg	0.55	0.85	0.62	4000
Weighted	0.85	0.74	0.76	4000

Approche 3 – ResNet50 + Histogramme (MLO) – Entraînement

Meilleure époque 7/10 – Val Acc 83.36 %




Approche 3 – ResNet50 + Histogramme (MLO) – Test

Test Acc 85 % (2000 images MLO) – **meilleure accuracy globale du mémoire** – mais rappel nul sur la classe A

ResNet50 + Histogramme (vues MLO) – Résultat du test final

2000 images de test · Accuracy globale : 85 % · Classe A non reconnue (0/10)

Matrice de confusion (test)




Métriques par classe

	Precision	Recall	F1-score	Support
Densité A	0.00	0.00	0.00	10
Densité B	0.72	0.55	0.62	190
Densité C	0.88	0.94	0.91	1530
Densité D	0.70	0.57	0.63	270
Accuracy			0.85	2000
Macro avg	0.57	0.51	0.54	2000
Weighted	0.83	0.85	0.84	2000

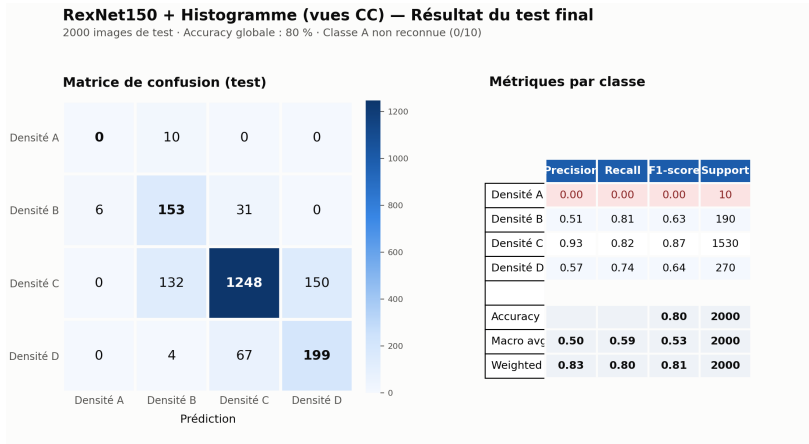
Approche 4 – RexNet150 + Histogramme (CC) – Entraînement

Meilleure époque 2/5 – Val Acc 81.56 %



Approche 4 – RexNet150 + Histogramme (CC) – Test

Test Acc 80 % (2000 images CC)



Approche 5 – Modèle 1 : RexNet150 + GLCM (CC)


Val Acc 73.42 % – Test Acc 74.85 % (2000 images CC)

Entraînement

RexNet150 + GLCM (vues CC) — Résultat de l'entraînement

Meilleur modèle (Époque 10/10) · Train Acc 87.98 % · Val Acc 73.64 % (1597 images)

Matrice de confusion (validation)



Métriques par classe


	Precision	Recall	F1-score	Support
Densité A	0.80	0.50	0.62	8
Densité B	0.51	0.82	0.63	166
Densité C	0.93	0.71	0.81	1219
Densité D	0.43	0.83	0.56	204
Accuracy			0.74	1597
Macro avg	0.67	0.72	0.65	1597
Weighted	0.82	0.74	0.76	1597

Test

RexNet150 + GLCM (vues CC) — Résultat du test final

2000 images de test (vue CC) · Accuracy globale : 74.85 % · Bug de normalisation GLCM corrigé

Matrice de confusion (test)



Métriques par classe

	Precision	Recall	F1-score	Support
Densité A	0.33	0.10	0.15	10
Densité B	0.51	0.87	0.65	190
Densité C	0.95	0.71	0.82	1530
Densité D	0.45	0.88	0.60	270
Accuracy			0.75	2000
Macro avg	0.56	0.64	0.55	2000
Weighted	0.84	0.75	0.77	2000

Approche 5 – Modèle 2 : ResNet50 + GLCM (MLO)


Val Acc 72.81 % – Test Acc 75.95 % (2000 images MLO)

Entraînement

ResNet50 + GLCM (vues MLO) -- Résultat de l'entraînement

Meilleur modèle (Époque 10/10) · Train Acc 85.78 % · Val Acc 72.86 % (1603 images)

Matrice de confusion (validation)



Métriques par classe


	Precision	Recall	F1-score	Support
Densité A	0.50	0.23	0.32	13
Densité B	0.44	0.89	0.59	152
Densité C	0.93	0.70	0.80	1211
Densité D	0.47	0.79	0.59	227
Accuracy			0.73	1603
Macro avg	0.59	0.65	0.57	1603
Weighted	0.82	0.73	0.75	1603

Test

ResNet50 + GLCM (vues MLO) -- Résultat du test

Test Acc 75.95 % (2000 images MLO)

Matrice de confusion (test)



Métriques par classe

	Precision	Recall	F1-score	Support
Densité A	0.33	0.10	0.15	10
Densité B	0.49	0.92	0.64	190
Densité C	0.95	0.73	0.83	1530
Densité D	0.49	0.84	0.62	270
Accuracy			0.76	2000
Macro avg	0.56	0.65	0.56	2000
Weighted	0.84	0.76	0.78	2000

Résultat invalidé

Le run initial (Train 84.98 %, Val 86.68 %, Test 84 %) chargeait ses données depuis un répertoire personnel d'un autre compte du cluster – ce n'était pas une réplique indépendante. Résultat retiré du mémoire, code corrigé. Faute de temps, pas de réentraînement – le principe « Histogramme » reste couvert par les Approches 3 et 4.

Approche 6 – Architecture originale (RexNet150/CC + ResNet50/MLO)


Val Acc 85.80 % (Époque 2/10) – **Test Acc 83.00 %** (2000 paires)

Entraînement

Architecture originale (RexNet150/CC + ResNet50/MLO) -- Résultat de l'entraînement

Meilleur modèle · Train Acc 77.01 % · Val Acc 85.80 % (352 Images)

Matrice de confusion (validation)



Métriques par classe


	Precision	Recall	F1-score	Support
Densité A	0.00	0.00	0.00	0
Densité B	0.76	0.59	0.67	32
Densité C	0.89	0.90	0.89	230
Densité D	0.82	0.84	0.83	90
Accuracy			0.86	352
Macro avg	0.62	0.58	0.60	352
Weighted	0.86	0.86	0.86	352

Test

RexNet150/CC + ResNet50/MLO (architecture originale) -- Résultat du test final

Test Acc 83.00 % (2000 paires CC+MLO) · Meilleur checkpoint : Époque 2/10 (Val Acc 85.80 %)

Matrice de confusion (test)



Métriques par classe

	Precision	Recall	F1-score	Support
Densité A	0.14	0.20	0.17	10
Densité B	0.72	0.57	0.64	190
Densité C	0.91	0.88	0.89	1530
Densité D	0.57	0.76	0.65	270
Accuracy			0.83	2000
Macro avg	0.59	0.60	0.59	2000
Weighted	0.84	0.83	0.83	2000

Approche 6 – Variante siamoise (EfficientNet-B0, poids partagés)


Val Acc 84.38 % (Époque 4/10) – **Test Acc 85.00 %** – meilleur résultat des 4 variantes

Entraînement

Variante siamoise (EfficientNet-B0, poids partagés) -- Résultat de l'entraînement

Meilleur modèle : Train Acc 79.78 % · Val Acc 84.38 % (352 images)

Matrice de confusion (validation)



Métriques par classe


	Precision	Recall	F1-score	Support
Densité A	0.00	0.00	0.00	0
Densité B	0.78	0.66	0.71	32
Densité C	0.83	0.96	0.89	230
Densité D	0.93	0.62	0.75	90
Accuracy			0.84	352
Macro avg	0.64	0.56	0.59	352
Weighted	0.85	0.84	0.84	352

Test

EfficientNet-B0 (variante siamoise, poids partagés) -- Résultat du test final

Test Acc 85.00 % (2000 paires CC+MLO) · Meilleur checkpoint : Époque 4/10 (Val Acc 84.38 %)

Matrice de confusion (test)



Métriques par classe

	Precision	Recall	F1-score	Support
Densité A	0.12	0.20	0.15	10
Densité B	0.69	0.59	0.64	190
Densité C	0.89	0.92	0.91	1530
Densité D	0.69	0.61	0.65	270
Accuracy			0.85	2000
Macro avg	0.60	0.58	0.59	2000
Weighted	0.84	0.85	0.84	2000

Approche 6 – Fusion même-vue : RexNet150 + ResNet50 (MLO)


Val Acc 74.62 % – Test Acc 74.85 % (2000 images MLO)

Entraînement

RexNet150 + ResNet50 (fusion même-vue, MLO) — Résultat de l'entraînement

Meilleur modèle (Époque 10/10) - Train Acc 88.74 % - Val Acc 74.61 % (1603 images)

Matrice de confusion (validation)



Métriques par classe


	Precision	Recall	F1-score	Support
Densité A	0.40	0.15	0.22	13
Densité B	0.47	0.84	0.60	152
Densité C	0.94	0.72	0.82	1211
Densité D	0.49	0.86	0.62	227
Accuracy			0.75	1603
Macro avg	0.57	0.64	0.57	1603
Weighted	0.83	0.75	0.76	1603

Test

RexNet150 + ResNet50 (fusion même-vue, MLO) — Résultat du test final

2000 images de test (vue MLO) - Train Acc 88.74 % - Val Acc 74.62 % - Test Acc 74.85 %

Matrice de confusion (test)



Métriques par classe

	Precision	Recall	F1-score	Support
Densité A	0.00	0.00	0.00	10
Densité B	0.50	0.87	0.64	190
Densité C	0.95	0.72	0.82	1530
Densité D	0.46	0.87	0.60	270
Accuracy			0.75	2000
Macro avg	0.48	0.61	0.51	2000
Weighted	0.84	0.75	0.77	2000

Approche 6 – Fusion même-vue : DenseNet121 + ResNet50 (CC)


Val Acc 75.69 % – Test Acc 76.35 % (2000 images CC)

Entraînement

DenseNet121 + ResNet50 (fusion même-vue, CC) — Résultat de l'entraînement

Meilleur modèle (Époque 10/10) · Train Acc 90.01 % · Val Acc 75.70 % (1597 images)

Matrice de confusion (validation)



Métriques par classe


	Precision	Recall	F1-score	Support
Densité A	0.75	0.38	0.50	8
Densité B	0.58	0.80	0.67	166
Densité C	0.93	0.74	0.83	1219
Densité D	0.43	0.84	0.57	204
Accuracy			0.76	1597
Macro avg	0.67	0.69	0.64	1597
Weighted	0.83	0.76	0.77	1597

Test

DenseNet121 + ResNet50 (fusion même-vue, CC) — Résultat du test final

2000 images de test (vue CC) · Train Acc 90.01 % · Val Acc 75.69 % · Test Acc 76.35 %

Matrice de confusion (test)



Métriques par classe

	Precision	Recall	F1-score	Support
Densité A	0.50	0.10	0.17	10
Densité B	0.55	0.86	0.67	190
Densité C	0.95	0.74	0.83	1530
Densité D	0.46	0.87	0.60	270
Accuracy			0.76	2000
Macro avg	0.61	0.64	0.57	2000
Weighted	0.84	0.76	0.78	2000

Variante	Train Acc	Val Acc	Test Acc
Fusion même-vue MLO (RexNet150+ResNet50)	88.74 %	74.62 %	74.85 %
Fusion même-vue CC (DenseNet121+ResNet50)	90.01 %	75.69 %	76.35 %
Architecture originale (RexNet150/CC+ResNet50/MLO)	77.01 %	85.80 %	83.00 %
Variante siamoise (EfficientNet-B0)	79.78 %	84.38 %	85.00 %

Approche 7 – Cascade hiérarchique (ViT)

Test Acc 42.53 % (4000 images) – très en retrait par rapport à la classification directe (70 %)

Routage Étape 1


Modèle 2 isolé

Test final

Cascade hiérarchique (ViT) -- Résultat du test final

Test Acc 42.53 % (4000 images) - seul de routage Étape 1 optimisé sur validation (0.5102)

Matrice de confusion (test)




Métriques par classe

	Precision	Recall	F1-score	support
Densité A	0.41	0.43	0.42	800
Densité B	0.30	0.09	0.13	960
Densité C	0.52	0.69	0.60	1440
Densité D	0.28	0.34	0.31	800
Accuracy			0.48	4000
Macro avg	0.38	0.39	0.36	4000
Weighted	0.40	0.43	0.39	4000


Cascade hiérarchique (ViT) -- Routage Étape 1

Rappel (A,B) : 47.39 % · Rappel (C,D) : 86.96 %



Cascade hiérarchique (ViT) -- Modèle 2 isolé (A vs B)

Accuracy 52.90 % (1760 images A+B du test, hors effet du routage Étape 1)



Approche 7 – Cascade hiérarchique (ResNet50)

Test Acc 48.50 % (4000 images) – meilleur que ViT, mais toujours en retrait

Routing Étape 1

Cascade hiérarchique (ResNet50) -- Routing Étape 1


Rappel routing (A,B): 79.00 % · Accuracy routing globale: 75.65 %

Test final

Cascade hiérarchique (ResNet50) -- Résultat du test final


Test Acc 48.50 % (4000 images) · Seuil de routing optimisé sur validation (0.1899)

Matrice de confusion (test)



Métriques par classe


	Precision	Recall	F1-score	Support
Densité A	0.00	0.00	0.00	20
Densité B	0.25	0.76	0.37	380
Densité C	0.88	0.48	0.60	3093
Densité D	0.21	0.47	0.29	540
Accuracy			0.48	4000
Macro avg	0.33	0.42	0.32	4000
Weighted	0.72	0.48	0.53	4000



Modèle 2 isolé

Cascade hiérarchique (ResNet50) -- Modèle 2 (A vs B) isolé

Accuracy isolée : 93.50 % (400 images A+B, hors routing)

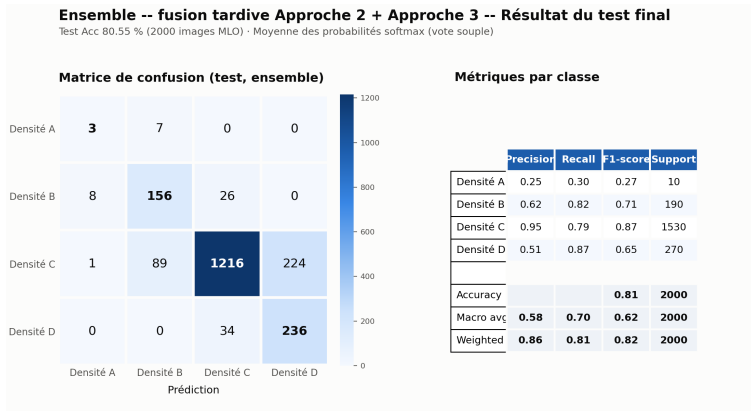


Maillon faible différent selon le backbone : Modèle 2 (A vs B) pour ViT, Modèle 3 (C vs D) pour ResNet50.

Approche 8 – Ensemble par fusion tardive (Approche 2 + Approche 3)


$$p_{\text{ens}}(x) = \frac{1}{2} \left(p^{(2)}(x) + p^{(3)}(x) \right), \quad \hat{y}_{\text{ens}}(x) = \arg \max_c p_{\text{ens},c}(x)$$

Test Acc 80.55 % (2000 images MLO) – meilleur macro F1 des trois (0.62), rappel classe A : 0 % → 30 %



FedAvg – Conception

- Client H1 : VinDr-Mammo (6801 images d'entraînement)
- Client H2 : DDSM/CBIS-DDSM (531 images d'entraînement) – substitut du réseau HELORA (données non accessibles)
- Modèle unique : ResNet50, une seule branche (contrainte du protocole FedAvg)



Algorithm 1 FedAvg – apprentissage fédéré entre les clients H1 et H2

```
1: procedure ServeurFedAvg
2:   Initialiser les poids globaux  $W_0$  (ResNet50, ImageNet)
3:   for chaque round  $t = 1, \dots, T$  do
4:     for chaque client  $k \in \{H1, H2\}$  do
5:        $W_t^k \leftarrow \text{ClientUpdate}(k, W_{t-1})$ 
6:     end for
7:      $W_t \leftarrow \sum_k \frac{n_k}{n} W_t^k$ 
8:   end for
9:   return  $W_T$ 
10: end procedure
11: procedure ClientUpdate( $k, W$ )
12:   for chaque époque locale  $e = 1, \dots, E$  do
13:     for chaque mini-lot  $b$  du client  $k$  do
14:        $W \leftarrow W - \eta \nabla_W \mathcal{L}(W; b)$ 
15:     end for
16:   end for
17:   return  $W$  au serveur
18: end procedure
```

▷ agrégation pondérée par la taille locale n_k


$E=1$ époque locale par round (15 rounds au total).

FedAvg – Résultats (15 rounds)

Accuracy de validation

Apprentissage fédéré (FedAvg) – Accuracy de validation par round

15 round(s) sur 15 · H1 = VinDr-Mammo (6801 img) · H2 = DDSM/CBIS-DDSM (531 img)




Accuracy globale entre 53.74 % (Round 14) et 70.82 % (Round 2) – pas de convergence stable, H1 (93 % du poids d'agrégation) domine largement H2.

Loss de validation

Apprentissage fédéré (FedAvg) – Loss de validation par round

15 round(s) sur 15 · H1 = VinDr-Mammo (6801 img) · H2 = DDSM/CBIS-DDSM (531 img)




FedAvg – Comparaison avec une baseline centralisée

Source	Test Acc (centralisé)	FedAvg (val, 15 rounds)
VinDr-Mammo	82.30 %	53.74 % – 70.82 %
DDSM/CBIS-DDSM	31.17 %	27.96 % – 46.24 %

- Sur VinDr : la fédération coûte réellement de la performance (5 époques centralisées vs 1 seule par round en fédéré)
- Sur DDSM : même fourchette que FedAvg – la faiblesse vient d'un décalage de domaine (films scannés vs numérique natif), pas de la fédération elle-même

Interprétabilité – t-SNE (Approche 3)


Espace latent (avant-dernière couche) projeté en 2D



B et D forment des zones assez distinctes ; C domine l'espace ; A trop rare pour conclure.

Interprétabilité – Grad-CAM (Approche 3)

3 exemples par classe – vérification de la stabilité du comportement du modèle



Classe C : foyer stable près du mamelon ($\sim 48\%$). Classe D : 2/3 exemples corrects, 1/3 s'effondre (2.3%). Classe A : constamment faible (2.7–6.1%).

Merci de votre attention

Questions / discussion